

# 高光谱图像的分类技术研究——何同弟博士论文

## 摘要

高光谱图像具有较高的数据维度，常规的图像分类方法在处理高光谱图像时有较大的限制，如何从大量的高光谱数据中快速而准确地挖掘出所需要的信息，实现高精度的分类，是亟待解决的问题。

本文的主要研究工作如下：

在对高光谱遥感影像进行预处理之后，对所用高光谱图像做了大气校正、几何校正，选取为二次多项式模型，重采样采用的是最近邻插值法，精度方面的要求得到了充分保证。

## 绪论

遥感按光谱分辨率可分为多光谱遥感(光谱分辨率在 $\text{pow}(10,-1)*\lambda$ 数量级范围内)，高光谱遥感（光谱分辨率在 $\text{pow}(10,-2)*\lambda$ 数量级范围内），超光谱遥感（光谱分辨率在 $\text{pow}(10,-3)*\lambda$ 数量级范围内）。

### 国内外研究现状

实际的应用中常规分类方法存在着如下几个方面的不足：

1. 由于Hughes现象的存在(特征维数增加到某一个临界点后，继续增加反而会导致分类器的性能变差)，随着高光谱图像波段的增加，训练样本数量的要求剧增，给分类带来了一定困难；
2. 高光谱数据特定的光谱物理含义往往被忽略，完全从纯数学的角度去进行波段选择和聚类，无形中浪费了高光谱数据的巨大内涵；
3. “同物异谱”、“同谱异物”现象的存在，从地物目标到影像的波谱响应的机理和作用过程十分复杂，即使是同一种物质，其光谱表现也存在着很大的差异；
4. 自然界中地物的分布都有其特定的一般性规律性，完全基于数学模型的分类算法，其结果常常具有明显的不合逻辑的地方。

目前高光谱遥感影像分类主要有两个思路：基于特征空间的影像分类方法和基于光谱匹配的影像分类方法。

#### 基于特征空间的影像分类方法

- 监督分类
  - 最小距离分类法
  - 最大似然分类法
  - 人工神经网络分类法
  - 支持向量机分类法
  - 模糊分类方法
  - 决策树分类
  - 专家系统分类
- 非监督分类
  - k-均值聚类法
  - 迭代自组织方法

#### 基于光谱匹配的遥感影像分类方法

- 基于光谱角度匹配方法

光谱角度匹配法（Spectral Angle Match，SAM），通过计算一个测量光谱（像元光谱）与一个参考光谱之间的“角度”来确定他们两者之间的相似性，夹角越小，光谱越相似。通过选择一种地物，以多个波段的灰度值作为一个多维矢量，将标准地物的光谱数据与待匹配的地物进行光谱向量的角度余弦值计算，将该像元归于余弦值最大的一类，将下一地物依次与各标准地物光谱向量进行角度余弦计算，重复上述过程直到地物全面分类为止。

光谱角度匹配强调了光谱的形状特征，大大减少了特征信息，但分类效率依然不高。
- 基于光谱编码的匹配方法

编码匹配方法是为了在光谱库中对特定目标进行快速查找和匹配，对光谱曲线进行编码，对编码结果进行匹配。识别时将实测光谱的编码矢量与参考图像的编码矢量比较，计算其匹配系数，以匹配系数的大小作为他们的相似性度量。编码技术压缩了数据量，既提高了处理效率，又能保证光谱的重要形态特征。常用的方法有光谱二值编码、多阈值编码和光谱吸收特征编码。其中最典型的就 是光谱二值编码技术。该算法对已知地物类别根据其光谱曲线进行二值编码0或者1，将各波段的灰度值和平均值作比较，大于等于均生成0，否则为1.这样每个像元产生一条二值编码曲线，与光谱库内的二值编码向量匹配并计算匹配系数，将待分类像元分到波段数目相似性最多的类别中，由此确定图像中的地物类别。

光谱二值编码技术虽然提高了高光谱数据的分析效率，但是有时不能提供合理的光谱划分，并且编码过程中会丢失许多光谱信息。
- 基于波形特征的匹配方法

基于波形特征的匹配分类方法的基本思想是从分析光谱特征入手，从光谱曲线上提取出有意义的光谱特征参量，通过少数的参数匹配来完成对影像像元的分类和识别，常用的有光谱吸收指数。

SAI(Spectral Absorption Index)光谱吸收指数，可用于高光谱遥感图像处理、鉴别光谱吸收特征。

### 论文研究内容

本文主要内容：

1. 分析了高光谱数据的高维空间特征及其对传统分类技术带来的挑战，围绕高光谱图像分类的难点，总结了高光谱影像分类的主要方法及其特点。
2. 分类之前对数据进行大气校正和几何校正。
3. 构建了基于自适应PSO（粒子群）优化参数的RBF神经网络分类模型。由于神经网络无法通过设定具体的结构和参数使算法达到最优，同时还寻找学习问题，采用自适应粒子群优化算法读神经网络的模型参数进行了优化，不仅能发挥神经网络的泛化映射能力，而且能够提高神经网络的收敛速度与学习能力。
4. 构建了基于自适应PSO优化参数的SVR的高光谱遥感分类模型。由于SVR在求解大规模问题时存在学习速度慢、存储空间需求量大等问题。采用PSO算法对SVR参数进行了优化，在一定程度上解决了高光谱数据标记样本不足的问题。
5. 构建了基于自适应稀疏表示的高光谱遥感分类模型。由于稀疏表示模型符合生物视觉系统特性，且能够提取图像的高级特征，由于其自身具有的这些特

点，所以很适合高光谱遥感分类。利用训练样本构建字典，聚类每一步迭代所产生的的余项，将聚类中心作为新的字典原子，然后将测试样本看成冗余字典中训练样本的线性组合，令字典能够更适应与样本的稀疏表示。将基于自适应稀疏表示模型用于高光谱遥感分类，并对各种分类方法得到的结果进行分类精度比较。

## 高光谱分类理论及其预处理

高光谱遥感是指利用很多很窄的电磁波段从感兴趣的物体，获取许多非常窄而且光谱连续的图像数据的技术。目前，一般将波长间隔10nm一下，波段数36个以上的遥感系统定义为高光谱遥感。高光谱数据的基本特点是空间分辨率告、光谱分辨率告、数据量大、信息量丰富，光谱通道数多达数十甚至数百个以上，而且各光谱通道间往往是连续的。

### 高光谱遥感图像分类理论

高光谱图像分类的主要目标是根据待测地物的空间几何信息与光谱信息将图像中的每个像素划分为不同的类别。从图像光谱的角度来说，高光谱遥感图像分类的效果取决于四个因素：

1. 类别的可分性
  2. 图像像元光谱空间的维数
- 一般来讲，在图像波段信噪比达到一定要求的情况下，光谱波段越多，越有利于分类。
3. 训练样本的数量
  4. 分类器类型和分类方案

### 高光谱图像分类的原则

进行多变量的图像分类，一般有以下三个原则：

1. 分类时应根据整体数据特征出发进行分类，而不能只根据个别变量的数值进行分类；
2. 分类的类别的离散程度用标准差向量或者协方差矩阵来衡量，类在特征空间的位置用类的均值向量表示，即该类的中心；
3. 分类区域的划分根据每类的统计特性出发或者是类与类之间的边界出发建立分类或者是判别函数。

### 高光谱图像分类的流程

高光谱遥感图像分类一般包括图像预处理、标记训练样本、特征提取及选择、分类判决及精度评价五个部分。

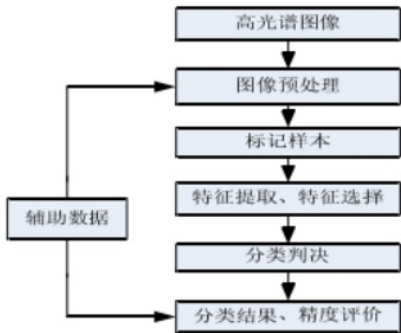


图 2.1 高光谱图像分类的一般流程

#### 1. 图像预处理

一般有：条带噪声去除、波段间配准、数据压缩、光谱定标、辐射定标、大气校正、几何定标。

#### 2. 标记训练样本

#### 3. 特征提取与特征选择

各波段间具有很强的相关性，为了消除数据间不必要的冗余信息，减少数据量和计算时间，需要对高光谱图像进行特征提取。

特征提取是通过映射和变换的方法，把原始模式空间的高维数据编程特征空间的低维数据，然后对特征更集中的低维数据进行处理。特征提取分为两类：一类是基于变换的方法，如主成分分析、最小噪声分离变换，小波变换等，这些降维方法的有点是将高维数据直接降低到低维，速度很快；另一类是基于非变换的，如波段选择等，它的优点是保持了图像的原有特征。

光谱特征提取即从原始数据中提取其特征参数，以满足后续处理要求。由电磁波理论可知相同物体具有相同的电磁波谱特征，不同物体由于物质组成、内部结构和表面状态不同，具有相异的电磁波谱特性，这是利用地物光谱特征来识别和区别地物的基础。

#### 4. 分类判决

由于高光谱图像分辨率很高，所以能够识别的类别的数目就比较多，用一些传统的分类方法来进行分类的话，分类效果就比较差了，这就需要一些根据图像特点和分类目的设计或选择恰当的分类器及其判决准则来提高分类精度，对未知区域的样本进行类别归属的判断。

#### 5. 分类结果和精度评价

常用的方法有 混淆矩阵、总体分类精度、kappa错分误差三种评价方法。

混淆矩阵主要用于比较分类结果和地表真实信息，可以把分类结果的精度显示在一个混淆矩阵里面。混淆矩阵是通过将每个地表真实像元的位置和分类图像中的相应位置和分类像比较。用  $M$  表示混淆矩阵， $M$  是一个  $T \times T$  的矩阵， $T$  是类别数量，那么  $M_{ij}$  表示类别  $j$  被分类为类别  $i$  的样本数量，若混淆矩阵中对角线上的元素值愈大，则表示分类结果的可靠性愈高，元素值愈小，则表示错误分类的现象愈严重。

总体分类精度（Overall Accuracy，OA）是指被正确分类的像元总和除以总像元数。

Kappa系数是在综合了用户精度和制图精度两个参数上提出的一个最终指标，它的含义就是用来评价分类图像的精度问题。如果两幅图像差异很大，则其Kappa系数小。也可以通过计算标准Kappa值来更好的检验分类结果的正确程度。它是通过把所有地表真实分类中的像元总数(  $N$  )乘以混淆矩阵对角线（  $X_k$  ）的和，再减去某一类地表真实像元总数与被误分成该类像元总数之积对所有类别进行求和的结果，再除以总像元数的平方差减去某一类中地表真实像元总

数与该类中被分类像元总数之积对所有类别进行求和的结果所得到的。

遥感影像预处理

- Envi软件可以用来做大气校正。
- ERDA软件可以做几何校正。

基于人工神经网络的高光谱遥感分类研究

人工神经网络具有自学习和自适应的能力，可以通过预先提供的一批相互对应是输入-输出数据，分析掌握两者之间潜在的规律，并根据这些规律，用新的输入数据来推算输出结果。人工神经网络，能够从大量的历史数据中进行聚类和学习，进而找到某些行为变化的规律，在模式识别、信号处理、自动控制、人工智能、自适应的人机接口、优化计算。通信等领域有广泛的应用。在各种遥感影像分类方法中，应用较多的是采用BP算法训练权值的多层前馈网络，但是由于BP神经网络用于函数逼近时，权值的调节用的是负梯度下降法，算法很可能陷入局部极值，造成网络训练失败的可能性比较大，全局逼近神经网络的学习速度很慢。RBF神经网络是一种性能优良的前馈型神经网络，它可以任意精度逼近任意的非线性函数，且具有全局逼近能力，从根本上解决了BP网络的局部最优问题，而且拓扑结构紧凑，结构参数可实现分离学习，收敛速度快。本章将BP和RBF神经网络运用到高光谱遥感图像分类中来，并分析它们在本实验的可行性，并用粒子群优化方法对神经网络的参数进行优化。

神经网络概述

大脑的学习过程就是神经元之间连接强度随外部激励信息做自适应变化的过程，大脑处理信息的结果由神经元的状态表现出来。

人工神经网络和基本功能

人工神经网络具有以下基本功能：

- 1. 联想记忆
- 2. 非线性映射

许多系统的输入与输出之间存在复杂的非线性关系，设计合理的神经网络通过对系统输入输出样本进行自动学习，能够以任意精度逼近任意复杂的非线性映射。神经网络的这一优良性能能使其可以作为多维非线性函数的通用数学模型。

- 3. 分类与识别

神经网络可以很好地解决对非线性曲面的逼近，因此具有很好的分类与识别能力。

- 4. 优化计算
- 5. 智能处理

人工神经元模型

有指导学习和无指导学习不是相互冲突的，比如在应用有指导学习训练一个网络后，再利用一些后期的无指导学习来使得网络自适应于环境的变化。

人工神经网络的模型

人工神经网络具有自组织、自学习、联想存储的功能和高速寻找优化解的能力，常见的形式有：

- 1. 感知器网络

最早的神经网络模型，是一个具有一层神经元、采用阈值激活函数的前向网络。通过对网络权值的训练，可以使感知器对一组输入矢量的响应达到元素为0或1的目标输出。

- 2. 线性神经网络

与感知器不同的是其神经元有一个线性激活函数，这允许输出可以是任意值，而不仅仅是0/1。

- 3. BP网络

BP是对非线性可微分函数进行权值训练的多层网络。多层前向网络采用反向传播学习算法（Back Propagation，BP）。

- 4. 反馈函数

反馈函数，又称为自联想记忆网络，其目的是为了设计一个网络，存储一组平衡点，使得当给网络一组初始值时，网络能通过自行运行而最终收敛到这个设计的平衡点上。反馈函数能够表现出非线性动力学系统的动态特性。

- 5. 自组织竞争人工神经网络

自组织竞争人工神经网络是基于生物结构和现象形成的。它能够对输入模式进行自组织训练和判断，并将其最终分为不同的类型。与BP网络相比，这种自组织自适应的学习能力进一步拓宽了人工神经网络在模式识别、分类方面的应用。另一方面，竞争学习网络的核心-竞争层，又是许多种某种其他神经网络模型的重要组成部分。

人工神经网络的特点

- 1. 分布式存储与容错性

信息在神经网络的存储是按内容分布于大量的神经细胞中，而且每个神经细胞实际上储存着多种不同信息的部分内容，局部的或部分神经元出现差错，不会影响全局结果，网络能够自动纠正错误。

- 2. 并行性

- 3. 信息的处理与存储的合二为一性

每个神经元都兼有处理与存储的功能，神经元之间连接强度的变化，反映了对信息的记忆，同时又与神经元对激励的响应一起反映了对信息的处理。

- 4. 自学习和自组织性

对外界事物的反映，通过神经元之间的连接强度不断增加，进行自学习、自组织。

- 5. 层次性和系统性

BP神经网络模型的建立

BP神经网络也称为误差反向传播神经网络，BP网络是由非线性变换但愿组成的最简单、最普遍、最通用的一种神经网络形式，BP神经网络是多层前馈神经网络，它采用误差反向传播学习算法。该网络算法的学习过程是由正向传播和反向传播两部分组成的，它是由非线性变换单元组成的一个从输入到输出高度非线性映射，属于前馈网络。

BP神经网络训练流程

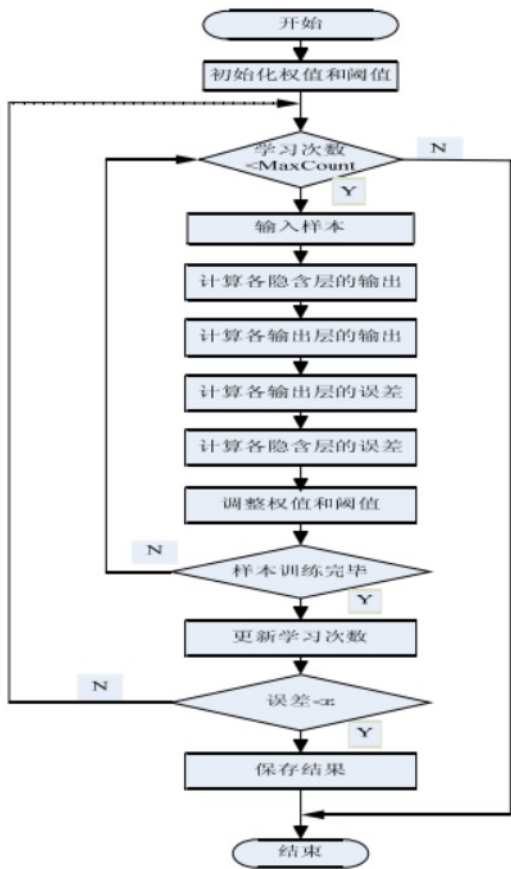


图3.6 BP神经网络的训练流程图

基于BP神经网络的分类流程

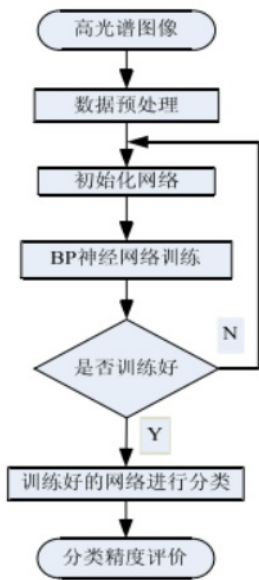


图3.7 高光谱图像分类流程图

RBF神经网络模型的建立

BP算法的实质是求解误差函数的最小值问题，由于它采用非线性规划中的最速下降方法（梯度下降），按误差函数的负梯度方向修改权值，由而通常存在学习效率低、收敛速度慢和易陷入局部极小状态，造成网络训练失败的可能性比较大。径向基函数（Radial Basis Function，RBF）神经网络是一种性能良好的前向网络，具有最佳逼近、训练简洁、学习收敛速度快以及克服局部最小值的性能，目前已经证明径向基网络能够以任意精度逼近任意连续的函数。

RBF神经网络的结构

径向基函数是多维空间插值的传统技术。RBF神经网络的基本思想是用径向基函数（RBF）作为隐单元的“基”，构成隐藏层的空间，隐藏层对输入矢量进行变换，将低维的模式输入数据转换到高维空间内，使得在低维空间内的线性不可分的问题在高维空间内线性可分。

RBF神经网络有很强的非线性拟合能力，可映射任意复杂的非线性关系，而且学习规则简单，便于计算机实现。具有很强的鲁棒性、记忆能力、非线性映射能力以及强大的自学习能力。具有全局逼近能力，从根本上解决了BP网络的局部最优问题，而且拓扑结构紧凑，结构参数可实现分离学习，收敛速度快。RBF网络和模糊逻辑能够很好的实现互补，提高神经网络的学习泛化能力。

输入层由信号源节点组成；第二层是隐层，隐层节点的变换函数是对中心点径向对称且衰减的非负非线性函数。第三层是输出层，一般是简单的线性函数，对输入模式做出响应。

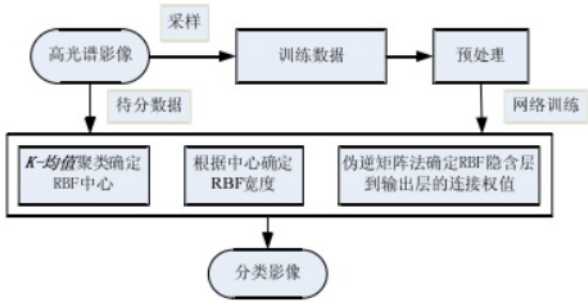
RBF神经网络输入层到隐含层之间的权值固定为1，隐含层单元的传递函数采用了径向基函数，隐含层神经元是将该层权值向量  $W_i$  与输入向量  $X_i$  之间的矢量距离与偏差  $b_i$  相乘后作为该神经元激活函数的输入。

RBF网络的学习算法

- RBF网络要学习的参数有三个：基函数的中心  $X_i$  和方差  $\sigma_i^2$ ，以及隐含层与输出层之间的权值  $w$ 。根据径向基函数中心选取方法的不同，RBF网络有多种学习方法，其中最常用的有四种学习方法：随机选取中心法、k-均值聚类算法、自组织选取中心法和正交最小二乘法。
1. 确定基函数的中心  $X_i$   
本文采用K-均值聚类算法来确定基函数的中心。
  2. 确定基函数的方差  $\sigma_i^2$
  3. 隐含层到输出层的权值  $w$

RBF网络的分类算法

- RBF网络分类器的确定如下:
1. 确定RBF隐含层神经元的中心  $X_i$   
通过“试选法”确定隐含层节点数目为5个，采用k-均值聚类算法确定高斯函数的中心  $X_i$ 。
  2. 确定RBF隐含层神经元的宽度  $\sigma_i^2$
  3. 确定输出层输出形式以及节点数  
由分类数来决定输出节点数。一个类对应一个节点，当输入模式归于某类时，对应此类的节点输出为1，反以为0。
  4. 确定RBF隐含层与输出层之间的连接权值。



RBF神经网络分类流程图如下图所示: 图3.9 RBF网络分类流程图

基于粒子群优化算法的RBF神经网络模型

粒子群优化算法（Particle Swarm Optimized, PSO）是模拟鸟群飞行觅食过程中，通过个体之间的协作，最终达到群体最优目的的行为。保留了基于种群的、并行的全局搜索策略，有较强的全局收敛能力和较强的鲁棒性，模型操作简单，避免了复杂的遗传操作。将PSO与RBF神经网络相结合，利用自适应PSO来训练神经网络，不仅能发挥神经网络的泛化映射能力，而且能够提高神经网络的收敛速度与学习能力。

粒子群优化算法

PSO受人工生命研究结果的启发、同模拟鸟群觅食过程中的迁徙和群聚行为而提出的一种基于群体智能的全局随机搜索算法。PSO和其他进化算法一样，也是基于“种群”和“进化”的概念，通过个体间的协作和竞争，实现复杂空间最优解的搜索；同时，PSO又不像其他进化算法那样对个体进行交叉、变异、选择等进化算子操作，而是将群体（swarm）中的个体看作的在D维搜索空间中没有质量和体积的粒子（particle），每个粒子以一定的速度在解空间运动，并向自身历史最佳位置p和邻域历史最佳位置g聚集，实现对候选集的进化。步骤如下：

1. 初始化种群数量，使它们随机的分布在平面上；
2. 根据模型评估每个粒子的位置；
3. 如果一个粒子当前的位置比它之前的位置好，则记录下新位置，记为p；
4. 确定种群中最好的粒子的位置，记为g；
5. 根据公式：
$$v_{i+1} = wv_i + c_1r_1(p_{id} - x_i) + c_2r_2(p_{gd} - x_i) \tag{3.10}$$
更新每个粒子的速度。 $c_1$  和  $c_2$  为学习因子，也称加速常数(acceleration constant),  $r_1$  和  $r_2$  为[0, 1]范围内的均匀随机数。

6. 根据公式:  $X_{i+1} = X_i + V_{i+1}$  更新每个粒子的位置。
7. 返回第2步重新迭代，直到满足停止条件； PSO流程图如下:

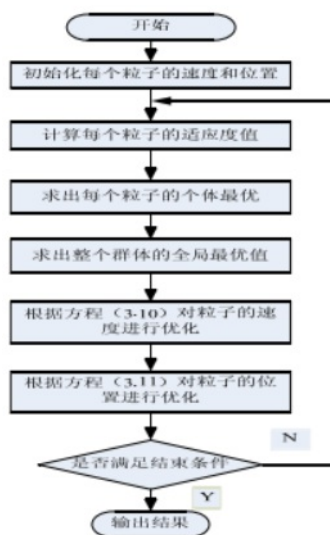


图3.10 PSO算法流程图

粒子群优化算法需调整参数主要包括，种群大小 $m$ ，学习因子 $c_1, c_2$ ，惯性权重 $W$ 。经过大量的实验结果对比，指出 $c_1, c_2$ 之和最好接近于4.0，通常 $c_1=c_2=2.05$ 。经典粒子群优化算法模型： $c_1=2.8$ ， $c_2=1.3$ ，种群数目  $m=30$ ，这些参数组合被称为经典参数集。

基于自适应PSO优化的RBF网络分类流程图如下图所示：

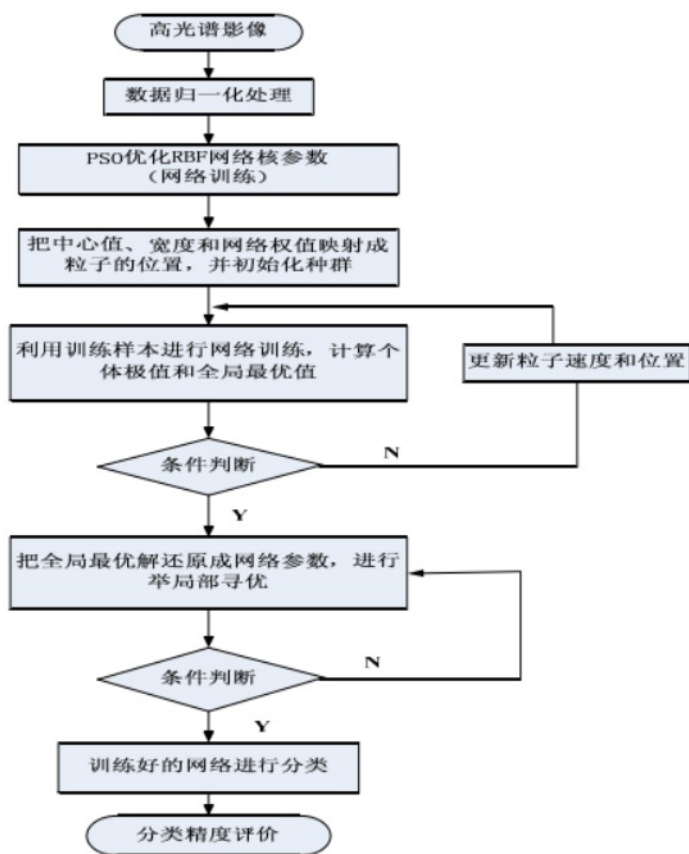


图3.11 基于PSO优化的RBF网络分类流程图

## 基于统计学习理论下的SVR高光谱遥感分类研究

SVM通过引入新的损失函数——不灵敏损失函数，实现了该方法能够像支持向量机一样具有较好的推广能力，不仅使回归估计具有鲁棒性，而且使它的解是稀疏的。SVM具有小样本学习、抗噪声性能、学习效率与推广性好的优点。目前针对高光谱数据进行分类还是仅仅局限于传统的分类方法，不但运算速度慢，分类精度低，而且出现了严重的huges现象。而在高光谱遥感分类中SVM具有明显的优越性，因而SVM应用被归纳为高光谱遥感分类最重要的进展之一。

### 支持向量机原理概述



SVM根据有限的样本信息在模型的复杂性（对特定训练样本的学习精度）和学习能力（无错误地识别任意样本的能力）之间寻求最佳的折中，以期获得最好的推广能力。SVM是一门专门研究小样本情况下机器学习规律的方法。

SVM的主要特点是：

- 1. 非线性映射的SVM方法的理论基础，SVM利用内积核函数代替向高维空间的非线性映射；
- 2. 它是结构风险最小化原则的具体实现，因此具有良好的推广能力；
- 3. 支持向量机的求解问题对应的是一个凸优化问题，因此局部最优解一定是全局最优解；
- 4. 核函数的成功应用，将非线性问题转化为线性问题求解；
- 5. 存在唯一极值点。

支持向量回归（SVR）

设样本集合为X，自变量x和因变量y之间存在函数依赖关系，通过SVR训练回归出一个最优函数，使得期望风险达到最小，使得每个输入样本的输出值和输入样本所对应的目标值相差不超过citation。

SVR分类模型的建立

RBF核函数是一个普遍适用的核函数，通过参数的选择，它可以适用于任意分布的样本。RBF核函数是目前在支持向量机中应用最广泛的一种核函数。

基于SVR的高光谱分类模型

- 1. 读入训练样本和测试样本。
- 2. 分类数据预处理

为了选取信息量大的波段，应用MNF（Minimum Noise Fraction）对图像进行预处理，可以判定图像数据内在的波段数，分离数据的噪声，减少随后处理中的计算需求量，用K-L变化提取特征明显的波段进行分类。

- 3. 数据归一化处理
- 4. SVR参数的选择

调用支持向量机工具箱，采用交叉验证的网格搜寻方法来确定核函数的参数、惩罚系数、不敏感损失函数的宽度的取值。

- 5. 用SVR对高光谱图像进行分类
- 6. 进行分类精度评价


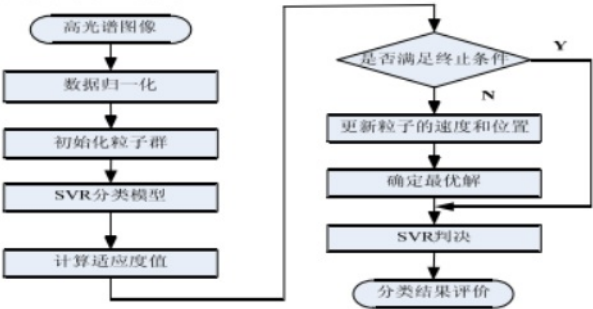


图 4.2 SVR分类流程图

基于自适应PSO的SVR高光谱分类模型的构建

SVR的分类结果主要受到核函数的参数、惩罚系数、不敏感损失函数的宽度。目前对于SVR参数的优选可以采用的有效方法很少。虽然试凑法是一种效果最好的方法，但是计算开销塔难以实现。现在有遗传算法、粒子群算法、蚁群算法来解决这类优选问题。粒子群优化算法是一种很有潜力的神经网络训练



算法，避免复杂的遗传操作。

图4.3 PSO-SVR分类流程图

基于稀疏表示的高光谱遥感分类研究

由于稀疏表示模型符合生物视觉系统特性，且能够提取图像的高级特征，稀疏表示是通过稀疏基或字典中少量元素的线性组合形式来描述信号或图像，在近年来被广泛地应用于信号和图像处理等领域，稀疏表示可以描述高光谱图像像元的特性，并成功应用于高光谱混合像元分解。目前稀疏表示已被广泛应用于图像处理的多个方面，如图像压缩、图像去噪、图像检索和图像识别等。

稀疏表示的理论基础

稀疏表示的应用主要是基于找出自然信号里面的高维信号，这些高维信号的同一类通常位于一个低维子空间，因此，对于每一个典型样本，都存在对一些

适当的编码语义信息的稀疏表示。

稀疏表示的模型

稀疏表示的定义是：在过完备系统中找到一个最稀疏或者接近最稀疏的表示。这里“过完备”是指样本的个数要大于样本的维数。图像的稀疏表示是指图像可完全或近似地有非常少的一组原子图像的线性组合表示，其是对多维数据进行线性分解的一种表示方法。

稀疏表示的优化算法

稀疏编码问题的目的是给定字典D，计算对信号x的最稀疏表示系数 $\alpha$ ，目前常用的稀疏编码问题的优化算法主要有三类：

1. 贪婪算法

代表性的有匹配追踪算法（matching pursuit，MP）和正交匹配追踪算法（orthonormal matching pursuit，OMP）。

2. 线性规划最优化算法

代表性的有基追踪算法（basic pursuit，BP）和Bregman迭代正则化算法。

3. 基于梯度的统计算法

代表性的有稀疏贝叶斯（sparse bayesian，SB）算法和FOCUSS算法。

基于自适应稀疏表示的高光谱图像分类

采用自适应方法构造稀疏字典，最后用构造好的字典对高光谱图像实现分类。

高光谱图像的稀疏表示

图像的稀疏表示是指图像可完全或近似地由非常少的一组原子图像的线性组合表示，而所有的原子图像即组成一个过完备的字典。当把所要分类的图像投影到由非常稀疏的原子组成的特征子空间时，其中只有很少的部分处于活跃状态，从而产生对该图像的稀疏表示。对图像进行表示时，人民通常使用完备的正交基，后来发现使用超完备基来表示图像会更加有效，能够得到更加稀疏的表示，超完备基的基底通常是冗余的，超完备基又被称为超完备字典，基元素被称为字典的原子。

自适应字典学习方法

随机森林分类方法

利用高光谱图像稀疏表示特征及光谱信息表示像元时，由于它们处于两个不同的表示空间，未来提高分类精度，利用分类器集成方法进行分类。随机森林是一种基于决策树的分类器集成算法。该算法是一种对参数选择不敏感，不存在过适应，分类结果稳定，学习训练速度较快的分类器集成算法，在解决多类问题上具有许多独特的优势。利用随机森林方法进行分类的最终分类结果由所有决策树通过多数投票决定。

利用随机森林方法进行分类的最终结果由所有决策树通过多数投票决定，由于随机森林采用随机子空间特征选择方法减少了输入空间的维数且能够快速构造决策树，同时根据多个决策树的结果采用投票策略决定分类结果，因此能够克服传统高光谱数据分类中所面临的数据维数高，训练样本数目少，运算速度慢等问题。

基于自适应稀疏表示的高光谱图像分类

结合稀疏表示特征及光谱信息，重复利用不同表示空间的特征信息，使用随机森林方法对高光谱遥感图像进行分类，步骤如下：

1. 字典学习

利用ASP(自适应稀疏表示)方法得到自适应学习字典D。

2. 特征提取

利用稀疏表示工具箱求像元y的稀疏表示特征。

3. 构造随机森林

利用像元y的稀疏表示特征和光谱信息分别构造随机森林。

4. 分类

采用多数投票策略，输出分类结果。

5. 分类结果评价